Выявление рисков нефропатии с помощью машинного обучения

На основе клинических данных пациентов

Пивторонис София Денисовна[1]
Хабибуллин Азамат Булатович[2]
Дорн Юлиане Сандра[3]

15 мая 2025 г.

[1]Исследователь, sdpivtoronis@edu.hse.ru
[2]Исследователь, abkhabibullin@edu.hse.ru
[3]Исследователь, idorn@edu.hse.ru

Содержание

1 Введение **3**
1.1 Актуальность . . . 3
1.2 Цели и задачи . . . 3
1.3 Описание данных . . . 3
1.4 Литературный обзор . . . 3

2 EDA **6**
2.1 Предобработка данных . . . 6
2.2 Визуализация данных . . . 6
2.3 Гипотеза и анализ . . . 8
2.4 PCA . . . 9

3 Обучение и валидация моделей **11**
3.1 Метрики . . . 11
3.2 Логическая регрессия . . . 12
3.3 SVM . . . 14
3.4 Сравнение моделей . . . 17

4 Заключение **17**
4.1 Выводы . . . 17
4.2 Перспективы . . . 18

5 Приложение **18**

6 Источники **19**

1 Введение

1.1 Актуальность

Рост случаев нефропатии создает серьезную проблему для здравоохранения. Для эффективной диагностики и лечения требуется анализ обширных медицинских данных пациентов, с чем традиционные методы справляются недостаточно хорошо. Поэтому возникает необходимость в разработке модели на основе машинного обучения, которая будет анализировать большие объемы данных, включая медицинские показатели, историю болезней и образ жизни пациентов. Применение таких технологий позволит повысить точность диагностики, ускорить процесс анализа данных и улучшить качество жизни пациентов. Проект направлен на оптимизацию процесса диагностики и лечения нефропатии, что делает его актуальным для современной медицины.

1.2 Цели и задачи

Целью данного проекта является разработка модели для предсказания риска развития нефропатии на основе имеющихся данных о пациентах. Задачи, которые необходимо решить в рамках проекта:

- Провести предварительный анализ данных (EDA) для понимания структуры и особенностей базы данных.
- Обработать данные, подготовить их к дальнейшему анализу и построению моделей.
- Сравнить результаты различных моделей и выбрать наилучший подход для предсказания нефропатии.

1.3 Описание данных

Исходные данные (табл. 1) содержат 443 наблюдения по 250 параметрам, включая:

- Демографические показатели (возраст, пол)
- Лабораторные анализы (гемоглобин, креатинин)
- Ангиографические параметры (баллы и векторы по Bolinger)
- Наличие сопутствующих заболеваний (нефропатия, диабет)

Параметр	Единицы измерения	Среднее	Стандартное отклонение
Возраст	лет	64.2	10.5
Гемоглобин	г/л	112.4	18.7
Креатинин	мкмоль/л	145.2	112.8

Таблица 1: Пример данных пациентов

Полный обзор на данные доступен в приложении к проекту.

1.4 Литературный обзор

Предсказание наличия заболеваний на основе анализа данных является важной задачей в области медицины и здравоохранения. Методы машинного обучения позволяют

эффективно обрабатывать большие объемы данных и выявлять закономерности, способствующие ранней диагностике заболеваний.

В рамках нашего проекта мы обратились к методам логическая регрессия и SVM. Но данном литературном обзоре рассмотрим большее количсетво классических методов машинного обучения, используемых для предсказания наличия болезни.

Логистическая регрессия [1]

Логистическая регрессия является одним из наиболее распространенных методов для бинарной классификации. Она позволяет оценивать вероятность наличия болезни на основе различных признаков.

Основные преимущества логистической регрессии:

- **Интерпретируемость:** Модель легко интерпретируется, что позволяет врачам понимать влияние каждого признака на вероятность заболевания.
- **Эффективность:** Хорошо работает на небольших и средних наборах данных.

Деревья решений [2]

Деревья решений представляют собой графическую модель, которая принимает решения на основе последовательных вопросов о признаках.

Преимущества:

- **Простота визуализации:** Легко интерпретировать и визуализировать, что делает их полезными в медицинских приложениях.
- **Отсутствие необходимости в нормализации данных:** Могут работать с данными разного масштаба.

Метод опорных векторов (SVM) [3]

Метод опорных векторов используется для классификации, находя оптимальную гиперплоскость, разделяющую классы.

Основные характеристики:

- **Эффективность при высоких размерностях**: Хорошо работает с большим количеством признаков.
- **Гибкость:** Позволяет использовать различные ядра для обработки нелинейных данных.

Случайный лес [4]

Случайный лес является ансамблевым методом, который комбинирует множество деревьев решений.

Преимущества:

- **Устойчивость к переобучению:** За счет объединения множества деревьев, случайный лес уменьшает риск переобучения.

- **Высокая точность:** Часто показывает лучшие результаты по сравнению с одиночными моделями.

Градиентный бустинг [5]

Градиентный бустинг, включая такие алгоритмы, как XGBoost и LightGBM, является мощным инструментом для предсказания.

Основные достоинства:

- **Высокая производительность:** Обеспечивает высокую точность предсказаний.
- **Гибкость:** Может использоваться для различных типов задач, включая регрессию и классификацию.

2 EDA

2.1 Предобработка данных

В процессе анализа данных была проведена очистка базы данных от пустых значений и статичных признаков. Были выявлены и обработаны числовые характеристики, содержащие запятые в названиях, и булевые колонки. Все пропуски в числовых колонках были заменены на -1, что позволяет избежать искажений в дальнейшем анализе. Это упрощает дальнейшую работу, снижает риск переобучения моделей и ускоряет вычисления.

2.2 Визуализация данных

Визуализации в этом проекте критически важны для понимания данных и результатов: они позволяют наглядно оценить распределение классов нефропатии, выявить потенциальные взаимосвязи между показателями и заболеванием.

Данная визуализация (рис. 1) показывает распределение возрастов пациентов с сердечно-сосудистыми заболеваниями, помогает выявить ключевые возрастные группы риска. График демонстрирует, что чаще всего с такими проблемами обращаются люди в возрасте 62–76 лет (пик заболеваемости), при этом распределение напоминает гауссову кривую с центром около 70 лет. Это позволяет сделать вывод о возраст-зависимом характере заболеваний: риск значительно возрастает после 60 лет, достигая максимума к 70–75 годам, а затем постепенно снижается.

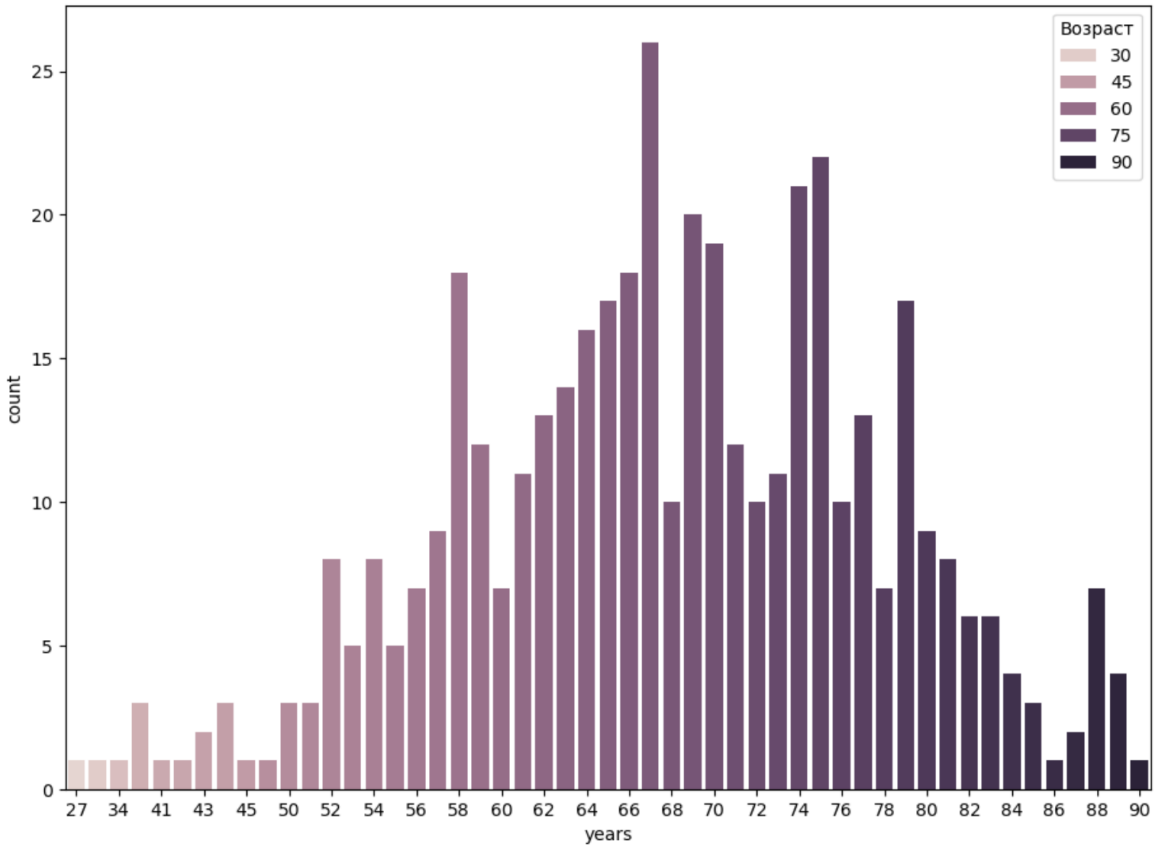

Рис. 1: Распределение возрастов пациентов с сердечно-сосудистыми заболеваниями

Гистограмма (рис. 2) демонстрирует распределение частоты диагнозов среди пациентов: лидируют тромбозы (вмешательства и послеоперационные), нефропатия и артериальные патологии (300–400 случаев), тогда как редкие состояния (например, аномалии строения артерий) встречаются менее чем у 50 пациентов, что подчеркивает необходимость фокуса на профилактику сосудистых осложнений.

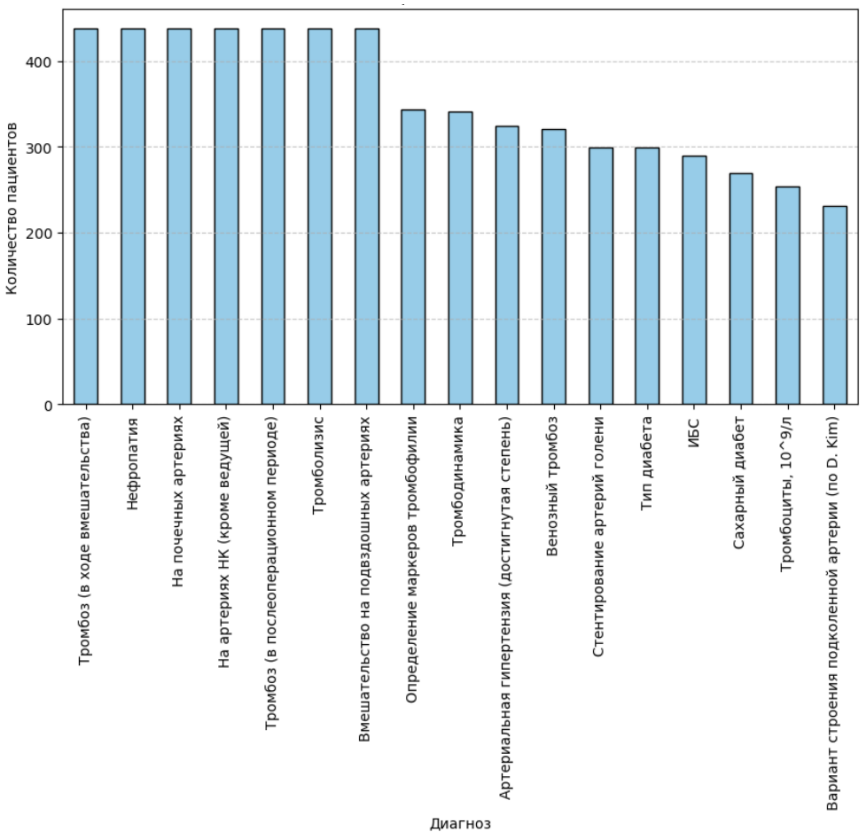

Рис. 2: Частота различных диагнозов

Гистограмма (рис. 3) показывает, что тромбоз в ходе вмешательства чаще всего встречается у пациентов в возрасте 60–80 лет, что согласуется с общей возрастной структурой данных. Распределение имеет правый скос, с резким ростом случаев после 60 лет и минимальным количеством у молодых пациентов (<50 лет).

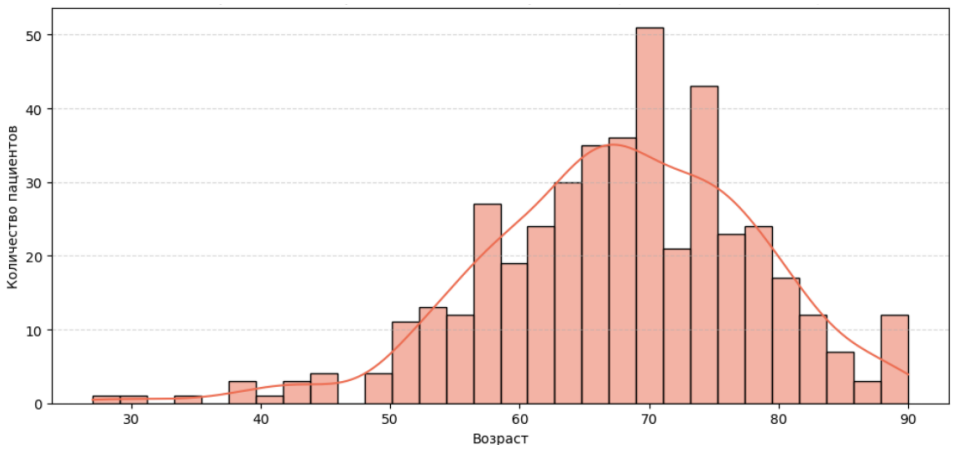

Рис. 3: Распределение возрастов пациентов с тромбозом (в ходе вмешательства)

2.3 Гипотеза и анализ

В рамках нашего проекта мы выдвинули гипотезу о том, что между диагнозом нефропатии и признаками, представленными в виде баллов и векторов, может существовать зависимость. Это исследование стало важным этапом анализа данных, поскольку понимание взаимосвязей между клиническими признаками и диагнозами может помочь в более точной диагностике и лечении заболеваний.

Для начала мы визуализировали распределение пациентов по диагнозу нефропатии с помощью гистограммы (рис. 4). На синей гистограмме мы представили количество пациентов с диагнозом "Нефропатия"(да или нет). Этот график позволил нам наглядно оценить, сколько пациентов страдают от этого состояния по сравнению с теми, у кого его нет. Мы заметили, что количество пациентов с нефропатией значительно меньше, чем без нее.

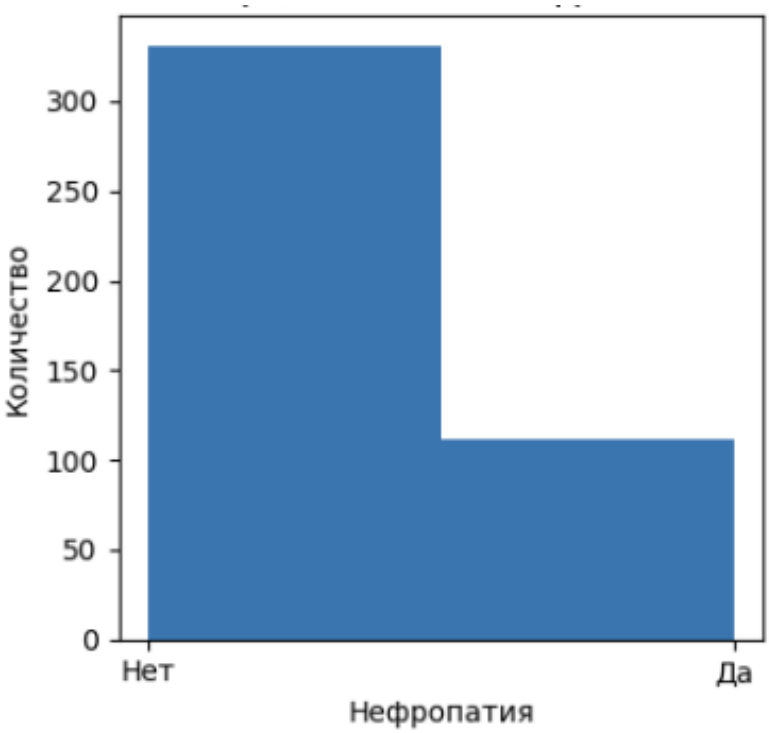

Рис. 4: Наспределение пациентов по диагнозу нефропатии

Далее мы сосредоточились на анализе векторов и баллов, относящихся к нефропатии. Мы выбрали признаки, связанные с Вектором ПББА и Баллом ПББА, и провели их анализ с использованием парных графиков (рис. 5). Эти графики позволили нам визуализировать возможные зависимости между значениями баллов и векторов и наличием нефропатии. Однако, несмотря на проведенный анализ, мы не обнаружили явной зависимости, что может свидетельствовать о сложности взаимосвязей в данных или о необходимости учета дополнительных факторов.

Таким образом, проведенное исследование позволило нам лучше понять распределение пациентов с нефропатией и их связь с определенными признаками. Несмотря на отсутствие четкой зависимости между анализируемыми признаками и диагнозом, результаты подчеркивают важность дальнейшего анализа и поиска других факторов, которые могут влиять на развитие нефропатии. Это исследование также открывает возможности для использования других методов анализа, таких как машинное обучение, для более глубокого понимания взаимосвязей в данных.

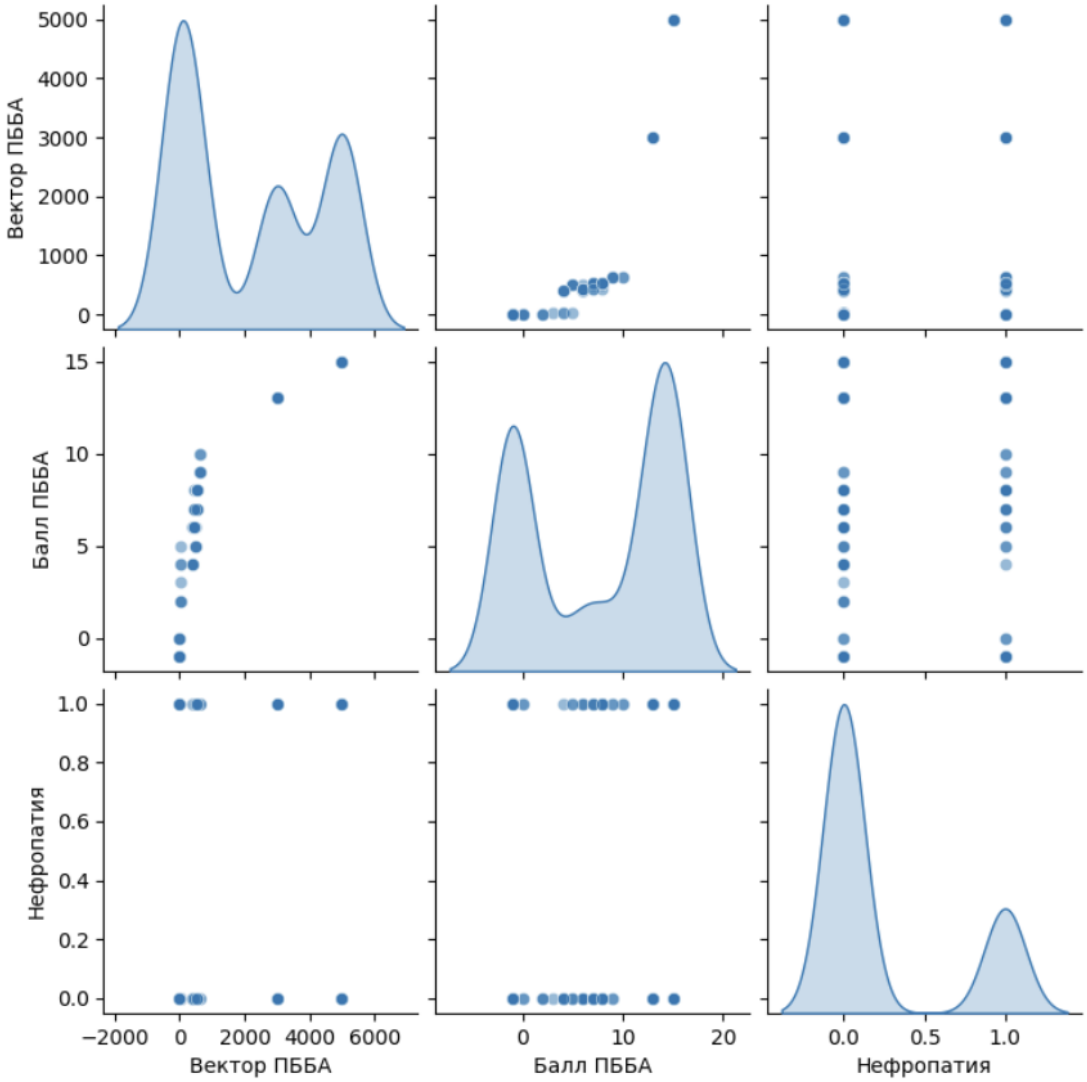

Рис. 5: Распределение возрастов пациентов с тромбозом (в ходе вмешательства)

2.4 PCA

Мы начали с того, что уменьшили размерность наших данных с помощью метода главных компонент. Это важный шаг, так как оригинальные данные могли иметь большое количество признаков, что затрудняло бы последующий анализ. Применение PCA позволило нам сжать данные до двух главных компонент, сохранив при этом большую часть информации.

Далее, мы попробовали визуально разделить пациентов на два класса - больных нефропатией и не больных. На полученном графике (рис. 6) мы видим, что точки, соответствующие пациентам с нефропатией, в основном расположены в левой части, а точки без нефропатии - в правой. Это наводит на мысль, что можно провести разделяющую линию между этими двумя группами.

Действительно, при анализе графика мы смогли подобрать приближенное уравнение прямой, которая разделяет пациентов на два класса: y = -1.25x - 3.25. Это достаточно простая модель, но она позволяет примерно отделить больных нефропатией от здоровых на основе двух главных компонент.

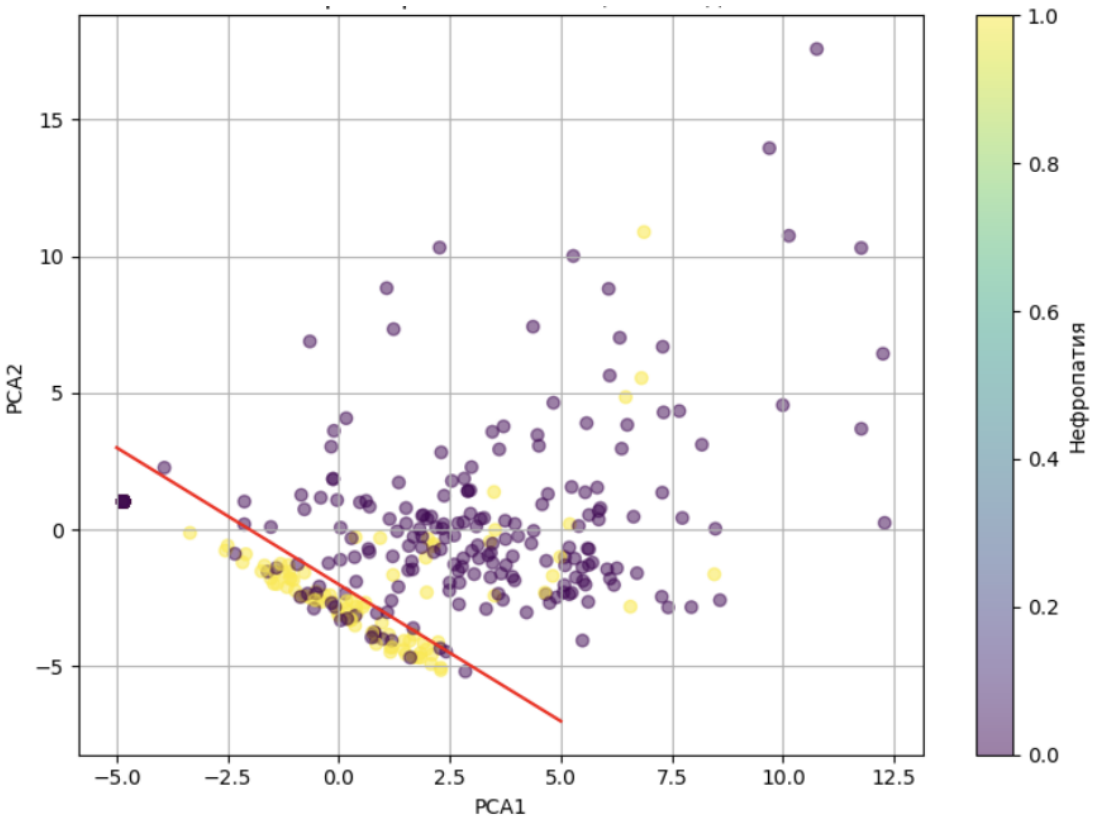

Рис. 6: Анализ понижения размерности с помощью PCA до 2-х компонент

Далее мы рассчитали точность нашей модели (рис. 7). Мы видим, что модель лучше предсказывает отсутствие нефропатии (precision 0.83, recall 0.55), чем ее наличие (precision 0.34, recall 0.68). Вероятнее всего это связано с тем, что в исходных данных было меньше пациентов с нефропатией. Сбалансированная точность составляет 0.612, что указывает на относительно невысокое качество простой линейной модели.

```
Classification report:
              precision    recall  f1-score   support

         Нет       0.83      0.55      0.66       331
          Да       0.34      0.68      0.45       112

    accuracy                           0.58       443
   macro avg       0.59      0.61      0.56       443
weighted avg       0.71      0.58      0.61       443

Balanced accuracy score: 0.6126996115666811
```

Рис. 7: Оценка модели

3 Обучение и валидация моделей

3.1 Метрики

В данной задаче диагностики нефропатии, наиболее важной метрикой является recall, поскольку ложноотрицательные ошибки, когда модель предсказывает отсутствие заболевания, когда оно на самом деле присутствует, могут иметь серьезные последствия для здоровья пациентов.

Рассмотрим принцип определения каждой метрики [6].

Accuracy (Точность)

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Пояснение:

TP - True Positives (верные положительные)
TN - True Negatives (верные отрицательные)
FP - False Positives (ложные положительные)
FN - False Negatives (ложные отрицательные)

Интерпретация:

- 1 - модель правильно классифицировала все объекты
- 0 - модель ошиблась на всех объектах
- Не подходит для несбалансированных данных

Balanced Accuracy (Сбалансированная точность)

$$\text{Balanced Accuracy} = \frac{1}{2}\left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP}\right)$$

Интерпретация:

- 1 - идеальная классификация для обоих классов
- 0.5 - случайное угадывание
- Особенно полезно для несбалансированных данных

Precision (Точность)

$$\text{Precision} = \frac{TP}{TP + FP}$$

Интерпретация:

- 1 - среди предсказанных положительных нет ложных
- 0 - все предсказанные положительные - ложные
- Важно, когда FP дорого обходятся (например, спам-фильтр)

Recall (Полнота)

$$\text{Recall} = \frac{TP}{TP + FN}$$

Интерпретация:

- 1 - модель нашла все положительные случаи
- 0 - модель не нашла ни одного положительного случая
- Важно, когда FN критичны (например, диагностика заболеваний)

F1-score (F-мера)

$$\text{F1} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Интерпретация:

- 1 - идеальный баланс между precision и recall
- 0 - либо precision, либо recall равен нулю
- Гармоническое среднее между precision и recall
- Полезно при несбалансированных классах

3.2 Логическая регрессия

Логистическая регрессия — это алгоритм классификации в машинном обучении, используемый для предсказания вероятности принадлежности объекта к определённому классу. Она применяется для:

- **Бинарной классификации** (например, да/нет или 0/1).
- **Мультиклассовой классификации** (более двух классов).

Основные математические формулы:

Логистическая (сигмоидная) функция

Преобразует линейную комбинацию признаков в вероятность (от 0 до 1):

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \text{где } z = w \cdot X + b$$

- w — веса признаков.
- b — смещение (bias).
- X — вектор признаков.

Функция потерь (Log Loss)

Минимизируется для обучения модели:

$$J(w, b) = -\frac{1}{n} \sum_{i=1}^{n} [y_i \log(\sigma(z_i)) + (1 - y_i) \log(1 - \sigma(z_i))]$$

- y_i — истинная метка класса.
- $\sigma(z_i)$ — предсказанная вероятность.

Мультиклассовая классификация (Softmax)

Для K классов:

$$P(Y = c \mid X) = \frac{e^{w_c \cdot X + b_c}}{\sum_{k=1}^{K} e^{w_k \cdot X + b_k}}$$

Ключевые особенности:

- Использует **сигмоиду** (бинарная) или **softmax** (мультикласс).
- Оптимизируется через **градиентный спуск**.
- Интерпретирует выход как **вероятность**.

В нашем случае:

Логистическая регрессия является базовым алгоритмом для задач бинарной классификации, к которым относится наша проблема диагностики нефропатии. Мы разделили данные на обучающую и тестовую выборки в соотношении 80/20 и использовали максимальное количество итераций, равное 1000, для сходимости модели. После обучения мы применили модель к тестовой выборке и получили следующие метрики качества (рис. 8):

- Точность (precision): 0.88
- Полнота (recall): 0.97
- F1-мера: 0.92
- Сбалансированная точность: 0.789

	precision	recall	f1-score	support
0	0.88	0.97	0.92	66
1	0.88	0.61	0.72	23
accuracy			0.88	89
macro avg	0.88	0.79	0.82	89
weighted avg	0.88	0.88	0.87	89

Рис. 8: Оценка логической регрессии

Эти показатели говорят о том, что модель логистической регрессии продемонстрировала высокую эффективность в предсказании наличия и отсутствия нефропатии. Сбалансированная точность около 0.79 указывает на то, что модель одинаково хорошо работает как для положительных, так и для отрицательных случаев.

Предоставим матрицу ошибок (рис. 9), которая наглядно показывает, что модель правильно классифицировала большинство примеров. Из 66 случаев без нефропатии она ошиблась только 2 раза, а из 23 случаев с нефропатией - 9 раз.

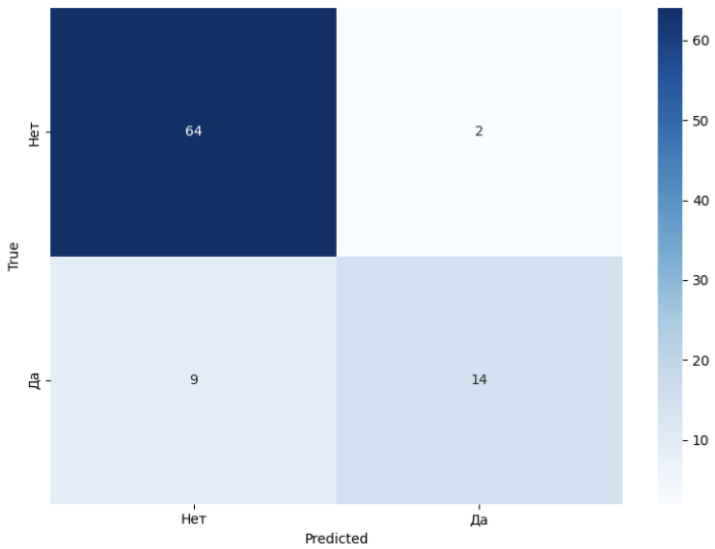

Рис. 9: Матрица ошибок

В целом, переход от простой линейной модели к логистической регрессии значительно улучшил качество предсказаний. Достигнутые метрики свидетельствуют о том, что данная модель может быть эффективно использована в практических целях для диагностики нефропатии.

3.3 SVM

Метод опорных векторов (SVM) — это алгоритм обучения с учителем, используемый для:

- **Классификации** (бинарной и многоклассовой).
- **Регрессии** (SVR — Support Vector Regression).

Ключевая идея: найти оптимальную разделяющую гиперплоскость в N-мерном пространстве, максимизирующую **зазор** (margin) между классами.

Основные математические формулы

Гиперплоскость

Уравнение гиперплоскости в линейном случае:

$$\mathbf{w} \cdot \mathbf{x} + b = 0,$$

где:

- $\mathbf{w}$ — вектор весов, перпендикулярный гиперплоскости.
- b — смещение (bias).

Расстояние до гиперплоскости

Для точки $\mathbf{x}_i$:

$$d_i = \frac{|\mathbf{w} \cdot \mathbf{x}_i + b|}{\|\mathbf{w}\|}.$$

SVM максимизирует минимальное расстояние до ближайших точек (опорных векторов).

Оптимизационная задача (Optimization Problem)

Для линейно разделимых данных:

$$\min_{\mathbf{w},b} \frac{1}{2}\|\mathbf{w}\|^2 \quad \text{при условии} \quad y_i(\mathbf{w}\cdot\mathbf{x}_i + b) \geq 1 \quad \forall i,$$

где $y_i \in \{-1, 1\}$ — метки классов.

Мягкий зазор (Soft Margin)

Допускает ошибки через slack-переменные ξ_i:

$$\min_{\mathbf{w},b} \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{n} \xi_i,$$

$$\text{при условии} \quad y_i(\mathbf{w}\cdot\mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

- C — параметр регуляризации (баланс между зазором и ошибками).

Двойственная задача (Kernel Trick)

Для нелинейных данных:

$$\max_{\alpha_i} \sum_{i=1}^{n} \alpha_i - \frac{1}{2}\sum_{i,j} \alpha_i\alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j),$$

$$\text{при условии} \quad 0 \leq \alpha_i \leq C, \quad \sum_{i=1}^{n} \alpha_i y_i = 0.$$

- α_i — множители Лагранжа (ненулевые только для опорных векторов).
- $K(\mathbf{x}_i, \mathbf{x}_j)$ — ядро (например, RBF, полиномиальное).

Ядерные функции

- **Линейное**: $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j$.
- **RBF (Гауссово)**: $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma\|\mathbf{x}_i - \mathbf{x}_j\|^2)$.
- **Полиномиальное**: $K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i \cdot \mathbf{x}_j + c)^d$.

Ключевые особенности

- Эффективен в высокоразмерных пространствах.
- Устойчив к переобучению (благодаря максимизации зазора).
- Поддерживает нелинейные границы через ядра.
- Чувствителен к выбору гиперпараметров (C, γ в RBF).

В нашем случае:

Мы обучили модель NuSVC, используя предварительно обработанные данные, включая стандартизированные признаки, полученные после применения метода главных компонент (PCA). Данные уже разделены на обучающую и тестовую выборки в соотношении 80/20. С помощью библиотеки Scikit-learn, мы настроили модель NuSVC и провели обучение на обучающей выборке. Модель продемострировала (рис. 10) высокую точность (0.88) и сбалансированную производительность с precision, recall и f1-score в диапазоне 0.73-0.95, при этом имея достаточную поддержку для обоих классов. Кроме того, значение balanced accuracy score 0.803 указывает, что NuSVC превосходит логистическую регрессию, подтверждая эффективность этого метода для нашей задачи.

	precision	recall	f1-score	support
0	0.89	0.95	0.92	66
1	0.83	0.65	0.73	23
accuracy			0.88	89
macro avg	0.86	0.80	0.83	89
weighted avg	0.87	0.88	0.87	89

Рис. 10: Оценка NuSVC

Согласно матрице ошибок (рис.11) модель допускает больше ошибок при предсказании наличия болезни (63 ложноотрицательных случая), чем при предсказании ее отсутствия (8 ложноположительных случаев).

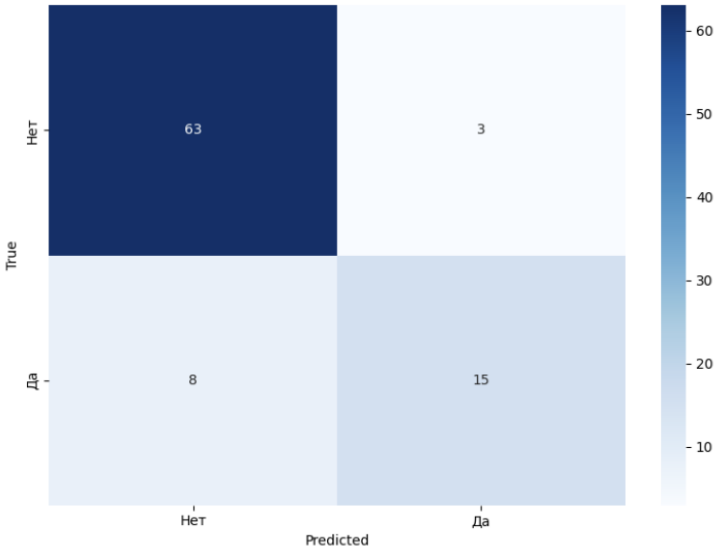

Рис. 11: Матрица ошибок

3.4 Сравнение моделей

Сравнивая результаты обучения двух моделей (табл. 2), можно сделать вывод, что модель NuSVC показывает более высокие показатели производительности по сравнению с предыдущей моделью. Модель NuSVC достигает balanced accuracy score 0.803, что на 0.02 выше, чем у предыдущей модели. Кроме того, NuSVC демонстрирует более высокие значения precision, recall и f1-score, что свидетельствует о ее лучшей способности распознавать как пациентов с нефропатией, так и без нее. Матрица ошибок NuSVC также показывает меньшее количество ложноположительных результатов, что важно с клинической точки зрения. Эти улучшения могут быть связаны с более эффективным использованием модели NuSVC нелинейных зависимостей в данных, которые не были в полной мере учтены предыдущей моделью. Таким образом, на основании представленных метрик можно заключить, что модель NuSVC является более предпочтительной для решения задачи диагностики нефропатии.

Metric	Logistic Regression	NuSVC
Precision	0.88	0.89
Recall	0.97	0.95
F1-score	0.92	0.92
Support	66	66
Accuracy	0.88	0.88
Balanced Accuracy	0.783359683794	0.803359683794

Таблица 2: Comparison of model performance metrics

4 Заключение

4.1 Выводы

В ходе данного проекта мы сравнили производительность двух моделей машинного обучения - логистической регрессии и SVM (NuSVC) - в задаче диагностики нефропатии. Анализ метрик показал:

- Balanced accuracy: NuSVC - 0.803, логистическая регрессия - 0.783
- Precision: NuSVC - 0.89, логистическая регрессия - 0.88
- Recall: NuSVC - 0.95, логистическая регрессия - 0.97
- F1-score: обе модели показали 0.92

Наиболее важной метрикой является recall, поскольку ложноотрицательные ошибки, когда модель предсказывает отсутствие заболевания, когда оно на самом деле присутствует, могут иметь серьезные последствия для здоровья пациентов, и поэтому модель должна правильно идентифицировать как можно больше случаев наличия заболевания, даже если это может быть достигнуто за счет некоторого снижения других метрик.

Анализ результатов показал, что по метрике recall, логистическая регрессия демонстрирует более высокий показатель (0.97) по сравнению с NuSVC (0.95). Это означает, что логистическая регрессия лучше справляется с правильной идентификацией случаев наличия заболевания.

Несмотря на то, что NuSVC показывает более высокие результаты по другим метрикам, таким как balanced accuracy и precision, в данном случае recall является ключевым критерием. Поэтому можно сделать вывод, что для решения этой конкретной задачи диагностики нефропатии, логистическая регрессия является предпочтительной моделью по сравнению с NuSVC.

4.2 Перспективы

Данный проект по диагностике нефропатии с использованием методов машинного обучения имеет хорошие перспективы для практического применения в медицинской сфере. Полученная модель NuSVC с высокой точностью и надежностью способна поддерживать врачей в раннем выявлении и диагностике нефропатии, что позволит своевременно назначать лечение и предотвращать дальнейшее развитие заболевания. Кроме того, данный подход может быть адаптирован и применен для диагностики других заболеваний, где требуется анализ большого количества медицинских показателей. В дальнейшем перспективным направлением является исследование влияния различных алгоритмов отбора признаков, а также применение более сложных моделей, таких как ансамблевые методы или нейронные сети, которые могут выявить более тонкие закономерности в данных и улучшить качество диагностики. Успешная реализация этого проекта в клинической практике позволит повысить эффективность медицинской помощи и улучшить качество жизни пациентов.

5 Приложение

Исходный код

Полный код проекта доступен в репозитории GitHub:

`https://github.com/polem1kaa/hse_project`

6 Источники

Искусственный интеллект

Monica AI [Электронный ресурс]. Режим доступа: https://monica.im/ru/home (дата обращения 20.05.2025)

Список литературы

[1] GeeksforGeeks. *Logistic Regression in Machine Learning.* [Электронный ресурс]. Режим доступа: https://www.geeksforgeeks.org/understanding-logistic-regression/ (дата обращения 20.05.2025)

[2] GeeksforGeeks. *Decision Tree.* [Электронный ресурс]. Режим доступа: https://www.geeksforgeeks.org/decision-tree/ (дата обращения 20.05.2025)

[3] GeeksforGeeks. *Support Vector Machine (SVM) Algorithm.* [Электронный ресурс]. Режим доступа: https://www.geeksforgeeks.org/support-vector-machine-algorithm/ (дата обращения 20.05.2025)

[4] Habr. *Random Forest.* [Электронный ресурс]. Режим доступа: https://habr.com/ru/articles/320726/ (дата обращения 20.05.2025)

[5] GeeksforGeeks. *Gradient Boosting in ML.* [Электронный ресурс]. Режим доступа: https://www.geeksforgeeks.org/ml-gradient-boosting/ (дата обращения 20.05.2025)

[6] Evidently AI. *Classification metrics guide* [Электронный ресурс]. Режим доступа: https://www.evidentlyai.com/classification-metrics/accuracy-precision-recall (дата обращения 20.05.2025)